Dự báo quỹ đạo của bão nhiệt đới khu vực Tây Thái Bình Dương bằng học máy và phương pháp Chuỗi hồi quy

Phạm Đình Quang Huy
Khoa học Dữ liệu
Trường Đại học Công nghệ Thông tin
ĐHQG-HCM
Email: 24520689@gm.uit.edu.vn

Huỳnh Lâm Bảo Khang
Khoa học Dữ liệu
Trường Đại học Công nghệ Thông tin
ĐHQG-HCM
Email: 24520738@gm.uit.edu.vn

Tóm tắt nội dung*—Dự báo quỹ đạo bão nhiệt đới là một nhiệm vụ quan trọng và cấp thiết không chỉ đối với Việt Nam mà còn trên toàn khu vực Tây Thái Bình Dương. Việc dự báo chính xác giúp các cơ quan chức năng chủ động đưa ra các biện pháp ứng phó kịp thời, qua đó giảm thiểu thiệt hại do thiên tai gây ra đối với con người và tài sản. Trong khi các phương pháp học máy hiện đại có khả năng xử lý các khoảng thời gian dự báo một cách độc lập và bỏ qua sự phụ thuộc về thời gian. Báo cáo này đề xuất sử dụng kĩ thuật Chuỗi hồi quy (Regressor Chain - RC) với dự báo đa khoảng thời gian (6h, 12h, 24h) nhằm mô hình hóa rõ ràng bản chất chuỗi của chuyển động bão nhiệt đới. Bằng cách tích hợp 88 đặc trưng dựa trên vật lý từ quỹ đạo IBTrACS, phương pháp này mô phỏng quan hệ nhân quả vật lý của chuyển động bão bằng cách dùng dự đoán trước đó làm đầu vào cho dự đoán tiếp theo. Kết quả thực nghiệm cho thấy sai số vị trí trung bình là $142.63 - 174.05km$ đối với dự báo 24 giờ (so với $144.5 - 154.16km$ với các mô hình độc lập). Độ ổn định hướng đạt 81.07-85.4% (vượt baseline 83.24%). Báo cáo này chứng minh rằng việc khai thác các mối phụ thuộc theo thời gian thông qua Chuỗi hồi quy (Regressor Chains) giúp tăng cường độ chính xác dự báo quỹ đạo bão nhiệt đới.

I. TỔNG QUAN

Bão nhiệt đới ở khu vực Tây Thái Bình Dương là một trong những thảm họa thiên nhiên tàn phá nhất trên toàn cầu, gây thiệt hại kinh tế hàng tỷ đô la và hàng nghìn người thiệt mạng mỗi năm [1]. Việc dự đoán quỹ đạo bão cho phép cảnh báo sớm, lập kế hoạch sơ tán hiệu quả và phân bổ nguồn lực tối ưu cho nhiệm vụ phòng chống thiên tai. Trong nhiều năm, các mô hình dự báo thời tiết, bão nhiệt đới được chú trọng phát triển. Tuy nhiên, sai số dự báo vẫn còn đáng kể, đặc biệt đối với các cơn bão có sự tăng trưởng nhanh chóng, đổi hướng đột ngột hoặc có hướng di chuyển rất thất thường.

Các mô hình dự báo truyền thống phải đối mặt với một số thách thức: (i) sự di chuyển của bão nhiệt đới bị chi phối bởi các động lực phi tuyến cao và đặc trưng bởi sự tương tác phức tạp giữa cường độ bên trong của bão, đối lưu, hiệu ứng Coriolis và các hoàn lưu khí quyển; (ii) các mô hình thường bị thiếu dữ liệu, có rất ít cơn bão cực đoan được ghi nhận trong lịch sử; (iii) quỹ đạo của bão thể hiện sự phức tạp về thời gian phụ thuộc vào đường đi, vị trí hiện tại của một cơn bão bị ảnh hưởng sâu sắc bởi các trạng thái trước đó và động lượng quán tính của nó.

Để khắc phục những hạn chế của các mô hình vật lý thuần túy, các ứng dụng gần đây của học máy (Machine Learning - ML) và học sâu (Deep Learning - DL) vào dự báo quỹ đạo bão đã cho thấy nhiều tiềm năng. Trong nghiên cứu của Tan và cộng sự [2], việc dùng Gradient Boosting Decision Trees (GBDT) đã cho thấy hiệu quả để dự đoán đường đi, trong khi các kiến trúc như Recurrent Neural Networks (RNN) [3] và Long Short-Term Memory (LSTM) [4] đã được triển khai để thu thập dữ liệu tuần tự.

Mặc dù có những tiến bộ đáng kể song vẫn tồn tại các khoảng trống nghiên cứu. Một vấn đề cơ bản là "Giả định các tầm dự đoán riêng biệt"(Independent Horizon Assumption). Hầu hết các nghiên cứu hiện có coi các tầm dự đoán khác nhau (ví dụ: 6h, 12h, 24h, 48h) là các nhiệm vụ hoàn toàn độc lập, huấn luyện các mô hình riêng biệt và độc lập cho mỗi khung thời gian [5]. Mô hình này mâu thuẫn trực tiếp với quy luật nhân quả vật lý vốn có trong chuyển động của bão, có thể được biểu diễn như sau:

$$position_{T+24h} = position_{T+12h} + \Delta position_{12h \to 24h} \quad (1)$$

$$position_{T+12h} = position_{T+6h} + \Delta position_{6h \to 12h} \quad (2)$$

Việc dự đoán độc lập từng tầm dự đoán khiến mô hình không tận dụng được thông tin trung gian và có thể tạo ra các dự đoán thiếu nhất quán theo thời gian, do bỏ qua các mối quan hệ tuần tự trong quá trình dịch chuyển của bão.

Hơn nữa, các phương pháp hiện tại thường mắc phải lỗi bỏ qua đa đầu ra (Multi-Output Neglect). Sự thay đổi về vĩ độ (ΔLat) và kinh độ (ΔLon) thường được dự đoán bởi các mô hình riêng biệt[6]. Công thức này bỏ qua thực tế rằng các biến này là các thành phần trực giao của cùng một vector vận tốc. Mối tương quan thống kê giữa chúng thường bị bỏ qua, điều này vô tình làm hạn chế khả năng nhận biết không gian của mô hình.

Các nghiên cứu gần đây đang tập trung phát triển học đa nhiệm (Multi-task learning) cho việc dự đoán đồng thời đường

đi và cường độ bão[7]. Tuy nhiên, có một khoảng trống rõ rệt liên quan đến sự phụ thuộc đầu ra trong dự báo đa tầm. Cụ thể, có rất ít nghiên cứu áp dụng Chuỗi hồi quy vào dự đoán đường đi của bão nhiệt đới mà mới dừng lại ở dự đoán thời tiết.

Chuỗi hồi quy (RC) là một quy trình mô hình hóa sự phụ thuộc đầu ra, hoạt động bằng cách xâu chuỗi các dự đoán, nghĩa là các dự đoán trước đó được đưa vào làm các đặc trưng tiếp theo cho các dự đoán tiếp theo[8]. Cấu trúc này nắm bắt rõ ràng các mối tương quan thống kê giữa các đầu ra trong khi vẫn duy trì khả năng giải thích của các thuật toán học máy truyền thống, không giống như các mạng noron phức tạp.

Dự báo quỹ đạo bão nhiệt đới là một bài toán phù hợp với phương pháp RC do ba yếu tố sau:

- *Thứ bậc thời gian* Các khoảng thời gian dự báo ($6h \rightarrow 12h \rightarrow 24h$) tạo thành một chuỗi thời gian tự nhiên.
- *Quan hệ nhân quả* Tọa độ không gian tương lai phụ thuộc chặt chẽ vào các vị trí trung gian.
- *Cấu trúc đa đầu ra* ΔLat và ΔLon là các thành phần vector có tương quan cao, cần được mô hình hóa cùng nhau chứ không phải riêng lẻ.

Để khắc phục những thiếu sót này, nghiên cứu đề xuất một phương pháp mới sử dụng RC tích hợp với Gradient Boosting. Những đóng góp chính của báo cáo này gồm bốn điểm:

1) Ứng dụng mới: Kết hợp RC trong dự báo đường đi bão nhiệt đới,
2) Cung cấp một khung đánh giá trên tập dữ liệu các cơn bão ở Tây Thái Bình Dương,
3) Đạt được mức giảm từ 144.5km xuống còn 142.63km 24 giờ. Hơn nữa, mô hình thể hiện độ ổn định hướng 85.4%, vượt quá mục tiêu 83.24% điển hình, và chứng minh bằng thực nghiệm rằng thứ tự chuỗi rất quan trọng để tối ưu hóa hiệu suất xác thực.

II. CƠ SỞ LÝ THUYẾT

A. Bài toán dự báo Đa đầu ra (Multi-Output), Đa tầm dự đoán (Multi-Horizon Prediction)

1) Định nghĩa bài toán: Bài toán dự báo đường đi của bão nhiệt đới có thể được định nghĩa thành nhiệm vụ dự báo đa đầu ra (Multi-Output), đa tầm dự báo (Multi-Horizon Prediction)[9], [7]. Giả sử trạng thái một cơn bão được xác định tại thời điểm T_0, tập các đặc trưng đầu vào được kí hiệu là $X_{T_0} \in \mathbb{R}^d$, với $d = 88$ là đại diện cho tập các đặc trưng động lực, môi trường và khí hậu. Kết quả đầu ra là vector liên tục $Y = [y_1, y_2, ..., y_k] \in \mathbb{R}^k$, với $k = 6$ cho cả ba khoảng dự đoán (6h, 12h và 24h).

Cụ thể, các thành phần vector trực giao của chuyển động bão được định nghĩa như sau:

$$y_1 = \Delta Lat_{6h}, \quad y_2 = \Delta Lon_{6h} \tag{3}$$

$$y_3 = \Delta Lat_{12h}, \quad y_4 = \Delta Lon_{12h} \tag{4}$$

$$y_5 = \Delta Lat_{24h}, \quad y_6 = \Delta Lon_{24h} \tag{5}$$

2) Independent & Dependent Modeling: Mô hình độc lập (Independent Model) coi việc dự báo của mỗi biến là một nhiệm vụ riêng biệt[**?**]. Do đó, mỗi đầu ra được dự đoán bởi một hàm ánh xạ độc lập f_j, bỏ qua các mối tương quan thống kê và tương tác vật lý cơ bản giữa bất kỳ y_i và y_j.

$$\hat{y}_j = f_j(X), \quad \forall j \in \{1, ..., k\} \tag{6}$$

B. Regressor Chain

1) Khái niệm: Nguồn gốc và sự phát triển Regressor Chain bắt nguồn từ Classifier chains - một kỹ thuật được hình thành cho phân loại đa nhãn, trong đó đầu ra là các chỉ báo nhị phân về sự hiện diện của nhãn[9], [10]. Điều quan trọng của phương pháp này là việc mô hình hóa các mối tương quan, từ đó giúp tăng cường đáng kể độ chính xác dự đoán so với việc mô hình hóa chúng một cách riêng lẻ. Classifier chains sau đó được mở rộng sang các miền đầu ra liên tục, được hình thức hóa thành RC, để giải quyết các bài toán hồi quy đa đầu ra phức tạp [11]. Các khảo sát gần đây về học đa đầu ra nhấn mạnh rằng chuỗi hồi quy đã thành công trong việc ánh xạ các phụ thuộc đầu ra mà không làm giảm hiệu quả của các thuật toán mục tiêu đơn.

2) Cơ sở toán học: $\{(X^{(i)}, Y^{(i)})\}_{i=1}^N$ trong đó $Y^{(i)} = [y_1^{(i)}, ..., y_k^{(i)}]$, RC yêu cầu thứ tự chuỗi được xác định trước $\pi = [\pi_1, \pi_2, ..., \pi_k]$. Trong giai đoạn huấn luyện, đối với mỗi mục tiêu j từ 1 đến k, cho π_j là đầu ra thứ j trong chuỗi [8]. Không gian đặc trưng được mở rộng bằng cách sử dụng các giá trị mục tiêu thực từ các nút trước đó:

$$\tilde{X}^{(i)} = [X^{(i)}, y_{\pi_1}^{(i)}, ..., y_{\pi_{j-1}}^{(i)}] \tag{7}$$

Sau đó, f_{π_j} được huấn luyện bằng cách ánh xạ $\tilde{X}$ đến y_{π_j}. Trong giai đoạn dự đoán, các mục tiêu thực không có sẵn. Không gian đặc trưng được mở rộng phụ thuộc hoàn toàn vào các dự đoán trước đó:

$$\tilde{X}_{test} = [X_{test}, \hat{y}_{\pi_1}, ..., \hat{y}_{\pi_{j-1}}] \tag{8}$$

$$\hat{y}_{\pi_j} = f_{\pi_j}(\tilde{X}_{test}) \tag{9}$$

Việc tích hợp chuỗi hồi quy vào dự báo quỹ đạo bão nhiệt đới được chứng minh bằng nhiều lý thuyết vật lý:

- **Nhân quả theo thời gian:** Chuyển động bị chi phối chặt chẽ bởi các định luật vật lý. Sự dịch chuyển từ T_0 đến $T + 6h$ quyết định tọa độ bắt đầu và vận tốc quán tính cho khoảng thời gian tiếp theo[3]. Chuỗi hồi quy phản ánh cấu trúc thông qua cơ chế dự báo tuần tự theo thời gian.
- **Khai thác tương quan:** Quỹ đạo của bão nhiệt đới thể hiện tính đa cộng tuyến cao giữa các tầm dự báo. Hơn nữa, vĩ độ và kinh độ trong cùng một tầm dự báo thể hiện sự ưu tiên hướng không gian. Chuỗi hồi quy khai thác rõ ràng các mối tương quan này thông qua không gian đặc trưng được mở rộng của chúng.
- **Giảm thiểu sự lan truyền lỗi:** Trong khi các mô hình tuần tự có nguy cơ tích lũy lỗi dự đoán, chuyển động của

bão nhiệt đới thường duy trì các quỹ đạo liên tục[12]. Tính nhất quán này giúp hạn chế sự khuếch đại sai số một cách hỗn loạn, từ đó làm cho lợi ích của việc mô hình hóa phụ thuộc theo chuỗi vượt trội hơn so với nhiễu tích lũy.

- **Khả năng giải thích:** Không giống như mạng nơ-ron, tính minh bạch cấu trúc của Chuỗi hồi quy cho phép các nghiên cứu phân tích kiểm tra các thứ tự thay thế và trích xuất tầm quan trọng của đặc trưng cho từng nút đầu ra.

3) Trình tự chuỗi trong RC: Một vấn đề quan trọng trong kiến trúc chuỗi là hiệu suất dự đoán rất nhạy cảm với trình tự được chọn. Đối với dự báo đường đi bão nhiệt đới, tồn tại một số thứ tự khả thi[13]:

- **Thời gian - Vĩ độ trước:** Tiến trình theo trình tự thời gian với vĩ độ được ưu tiên ($\Delta Lat_{6h} \rightarrow \Delta Lon_{6h} \rightarrow \Delta Lat_{12h} \rightarrow \dots$).
- **Thời gian - Kinh độ trước:** Tiến trình theo trình tự thời gian với kinh độ được ưu tiên.
- **Horizon trước:** Ưu tiên vĩ độ và kinh độ trên tất cả các Horizon trước. Do tính chất động lực phức tạp của bão nhiệt đới, việc dựa vào một trình tự tùy ý là không tối ưu.

Báo cáo này tiếp cận việc sắp xếp chuỗi như một nhiệm vụ tối ưu hóa siêu tham số, tìm kiếm trình tự tối ưu một cách thực nghiệm thông qua đánh giá tập dữ liệu xác thực.

III. PHƯƠNG PHÁP

A. Mục tiêu bài toán

Mục tiêu chính là dự đoán sự dịch chuyển vật lý của tâm bão trong các khoảng thời gian tương lai được chỉ định. Các biến mục tiêu được định nghĩa là sự thay đổi vô hướng về vĩ độ (ΔY) và kinh độ (ΔX)[**?**][14]:

$$\Delta Y = LAT_{T+h} - LAT_{T_0} \tag{10}$$

$$\Delta X = LON_{T+h} - LON_{T_0} \tag{11}$$

trong đó $h \in \{6h, 12h, 24h\}$ biểu thị các khoảng thời gian dự báo. Do đó, vector mục tiêu cho mỗi quan sát bao gồm sáu biến liên tục ($k = 6$).

Sau khi các vector dịch chuyển được dự đoán, tọa độ địa lý tuyệt đối của cơn bão tại thời điểm tương lai $T + h$ được tái tạo bằng phép cộng:

$$\hat{Position}_{T+h} = Position_{T_0} + (\Delta X_{pred}, \Delta Y_{pred}) \tag{12}$$

Trong các kiến trúc cơ bản, các ánh xạ cho vĩ độ và kinh độ được coi là hai hàm hồi quy độc lập:

$$f_{lat} : X \rightarrow \Delta Y \tag{13}$$

$$f_{lon} : X \rightarrow \Delta X \tag{14}$$

Tuy nhiên, như đã đề cập trước đó, phương pháp được dùng là chuyển từ các hàm riêng lẻ này thành một kiến trúc phụ thuộc tuần tự, gắn kết (Regressor Chain) để bảo toàn các mối tương quan không gian và thời gian.

B. Bộ dữ liệu

Để xây dựng không gian đặc trưng toàn diện, báo cáo này tích hợp ba bộ dữ liệu riêng biệt, chất lượng cao, đảm bảo sự thể hiện toàn diện về hành vi của bão nhiệt đới.

1) IBTrACS V4: Kho lưu trữ theo dõi bão tốt nhất quốc tế về quản lý khí hậu (International Best Track Archive for Climate Stewardship - IBTrACS) phiên bản 4 đóng vai trò là nguồn chính cho tọa độ và cường độ bão trong lịch sử[15]. Bộ dữ liệu được lọc để chỉ bao gồm các cơn bão trong lưu vực Tây Thái Bình Dương từ năm 2000 đến năm 2024. Để đảm bảo các mô hình học từ các cấu trúc bão ổn định về mặt vật lý đã được thiết lập chứ không phải các dị thường khí quyển, nhóm đã tạo bộ lọc kiểm soát chất lượng được áp dụng: chỉ giữ lại các bản ghi có tốc độ gió duy trì tối đa $WMO_WIND \geq 30$ knot và tuổi thọ bão vượt quá 3 ngày.

2) Tái phân tích ERA5 - Tác động môi trường: Sự chuyển động của bão nhiệt đới chịu tác động mạnh mẽ bởi các hoàn lưu khí quyển quy mô lớn. Đồ án sử dụng bộ dữ liệu tái phân tích ERA5 của ECMWF (độ phân giải không gian $0.25° \times 0.25°$[16], được tổng hợp theo khoảng thời gian 6 giờ) để trích xuất các đặc trưng tác động môi trường. Các đặc trưng chính bao gồm: vector gió theo phương kinh/vĩ tuyến tại độ cao 10m ($u10$, $v10$) đại diện cho dòng khí dẫn hướng, áp suất mực nước biển trung bình (msl), nhiệt độ bề mặt biển (sst) là nguồn năng lượng chính và độ phân kỳ độ ẩm tích hợp theo chiều dọc ($vimdf$) để chỉ ra cường độ đối lưu.

3) ENSO MEIv2 - Bối cảnh khí hậu vĩ mô: Để nắm bắt sự biến đổi khí hậu giữa các năm ảnh hưởng đến vị trí hình thành bão và các đường đi chủ yếu, nghiên cứu đã tích hợp chỉ số ENSO đa biến phiên bản 2 (MEIv2). Chỉ số hàng tháng này mã hóa hiệu quả các tác động ở cấp độ vĩ mô của các pha El Niño và La Niña trên toàn cầu[17].

C. Feature Engineering

Việc chuyển đổi dữ liệu khí tượng thô thành dạng biểu diễn tối ưu cho Machine Learning đòi hỏi phải xử lý feature engineeing chuyên biệt. Không gian đặc trưng $X_{T_0} \in \mathbb{R}^{88}$ được chia thành ba loại chức năng chính:

1) Đặc trưng động học: Để đưa các ràng buộc vật lý vào mô hình học máy, chúng ta cần trích xuất các biến động học để nắm bắt động lượng quán tính của cơn bão. Các biến trễ thời gian (từ $T - 6h$ đến $T - 24h$) về vị trí, cường độ và khoảng cách đến đất liền được trích xuất để cung cấp bối cảnh lịch sử[2]. Từ các tọa độ này, chúng ta tính toán vận tốc theo hướng:

$$V_{Zonal_{\Delta t}} = LON_T - LON_{T-\Delta t} \tag{15}$$

$$V_{Meridional_{\Delta t}} = LAT_T - LAT_{T-\Delta t} \tag{16}$$

$$V_{Actual_{\Delta t}} = \sqrt{V_{Zonal}^2 + V_{Meridional}^2} \tag{17}$$

Hướng chuyển động (Azimuth) được tính toán để hiểu các góc dịch chuyển:

$$\theta = \arctan 2(V_{Meridional}, V_{Zonal}) \text{ [độ so với hướng Đông]} \tag{18}$$

Hơn nữa, các đạo hàm bậc cao hơn như gia tốc tịnh tiến ($Acc_{Zonal_{12h}}$, $Acc_{Actual_{12h}}$) và gia tốc góc ($Angular_Acc =$ angle_diff($\theta_{current}, \theta_{past}$)) được thiết kế. Khoảng cách dịch chuyển vật lý thực tế được tính toán bằng công thức Haversine để tính đến độ cong của Trái đất[18].

2) Expanding Window Climatology: Lịch sử khí hậu là nguồn thông tin quan trọng trong dự báo khí tượng, nhưng việc sử dụng trung bình khí hậu toàn cầu có thể gây rò rỉ dữ liệu nếu bao gồm cả thông tin từ tương lai. Để khắc phục, nghiên cứu áp dụng phương pháp Expanding Window Climatology theo Manrique-Sunen và cộng sự [5]. Với mỗi cơn bão trong năm Y, các đặc trưng khí hậu (như tần suất bão lịch sử $X79$, vận tốc gió trung bình $X81$, và góc phương vị $X84$ trên lưới $2^\circ \times 2^\circ$) chỉ được tính từ dữ liệu các năm trước Y, nhằm đảm bảo không rò rỉ thông tin tương lai.

3) Các đặc điểm tác động môi trường: Các biến khí quyển ERA5 ($u10, v10, msl, sst, vimdf$) được ánh xạ tới tọa độ không gian hiện tại của cơn bão để đóng vai trò là các ràng buộc nhiệt động lực học và động học bên ngoài[19], cho phép mô hình học được mối quan hệ phức tạp giữa xoáy của cơn bão và dòng chảy điều khiển môi trường của nó.

4) Chống Data Leakage: Rò rỉ dữ liệu trong các tập dữ liệu không gian-thời gian là một vấn đề nghiêm trọng có thể làm tăng hiệu suất mô hình một cách giả tạo trong quá trình xác thực, đồng thời dẫn đến những thất bại trong quá trình triển khai vận hành. Báo cáo sử dụng phương pháp Holdout Validation để chia dữ liệu và được thể hiện như Bảng I [13] .

Bảng I: Phân chia dữ liệu theo thời gian

Phân chia	Năm	Mẫu	Mục đích
Train	2000–2020	9,376	Xây dựng mô hình và trích xuất mẫu
Valid	2021–2022	723	Điều chỉnh siêu tham số và dừng sớm
Test	2023–2024	804	Đánh giá hoạt động cuối cùng, không thiên vị

D. Quy trình huấn luyện

Để làm rõ cách tiếp cận được đề xuất, nhóm so sánh bốn mô hình chính cho dự báo đa tầng:

- **Independent Modeling:** Huấn luyện các mô hình riêng biệt cho mỗi tầng ($\hat{y}_{6h} = f_{6h}(X)$) [1]. Mặc dù phương pháp này tránh được sự tích lũy lỗi và cho phép tính toán song song, nhưng nó bỏ qua các phụ thuộc về thời gian, thường dẫn đến các quỹ đạo không nhất quán về mặt vật lý.
- **Regressor Chain (Đề xuất):** Hoạt động như một sự khái quát hóa đa chiều của phương pháp DirRec [12]. Nó mở rộng chuỗi vượt ra ngoài các bước thời gian để tạo thành chuỗi chéo tọa độ (kết hợp vĩ độ và kinh độ).

Phương pháp này có khả năng tương thích cao với các mô hình GBDT hiện đại[2]. Các thư viện hiệu suất cao như XGBoost và LightGBM [20], [21] cung cấp các ước lượng cơ sở mạnh mẽ cho các chuỗi này, nắm bắt hiệu quả các động lực phi tuyến tính trong không gian đặc trưng được mở rộng.

Dựa trên lý thuyết và bằng chứng thực nghiệm trước đó, báo cáo này đưa ra bốn giả thuyết chính:

1) **H1:** Mô hình RC sẽ vượt trội hơn so với các mô hình độc lập về Sai số Vị trí Trực tiếp bằng cách nắm bắt rõ ràng các mối phụ thuộc theo thời gian giữa các kỳ dự báo
2) **H2:** Trình tự kiến trúc (π) quyết định hiệu suất; Trình tự thời gian (ví dụ: $6h \to 12h \to 24h$) sẽ cho ra sai số thấp hơn so với các trình tự không theo trình tự thời gian.
3) **H3:** Vì các chuỗi giới hạn các dự đoán dựa trên trạng thái quán tính trước đó, phương pháp này sẽ mang lại những cải tiến tỷ lệ lớn hơn về Độ ổn định hướng.
4) **H4:** Do hành vi quỹ đạo vật lý mượt mà của các cơn bão nhiệt đới, tính dễ bị tổn thương về mặt lý thuyết của RC đối với sự lan truyền lỗi tuần tự sẽ ở mức tối thiểu.

IV. THỰC NGHIỆM

A. Thiết kế thực nghiệm

1) Môi trường Phần cứng và Phần mềm: Để đảm bảo tính khả thi và hiệu quả, tất cả các thí nghiệm được thực hiện trên một thiết lập tính toán tiêu chuẩn, với phần cứng gồm CPU Intel Core i7 (hoặc tương đương), 32GB RAM. Môi trường phần mềm được xây dựng trên Python 3.12, sử dụng các thư viện chính gồm pandas (v3.03), numpy (v2.4.6) , scikit-learn (≥ 1.0) cho GBDT và RC, XGBoost (≥ 1.5) và LightGBM (≥ 3.3) để khai thác các thuật toán boosting hiệu năng cao và xử lý dữ liệu thưa.

2) Quy trình tiền xử lý dữ liệu: Việc chuyển đổi dữ liệu khí tượng thô thành không gian đặc trưng 88 chiều cuối cùng ($X \in \mathbb{R}^{88}$) tuân theo một quy trình tiền xử lý nghiêm ngặt, tuần tự. Thứ tự thực hiện được cấu trúc như sau:

1) **'_01_ibtracs_clean.py':** Phân tích dữ liệu tọa độ bão nhiệt đới thô.
2) **'_02_enso_clean.py':** Đồng bộ hóa các chỉ số khí hậu vĩ mô MEIv2 theo thời gian với các quan sát bão.
3) **'_03_ERA5_clean.py':** Trích xuất và tổng hợp không gian các lưới khí quyển ($u10, v10, msl$, v.v.) tương ứng với hộp giới hạn của mỗi cơn bão.
4) **'_04_feature_engineering.py':** Hợp nhất tất cả các nguồn dữ liệu độc lập, áp dụng phương pháp khí hậu học cửa sổ mở rộng và tạo ra các đặc trưng động/động lực học.
5) **'_05_target_split.py':** Làm sạch các cơn bão giai đoạn cuối và tạo ra các mục tiêu ΔLat và ΔLon đa tầm dự báo.

B. Cấu hình huấn luyện

1) Early Stopping: Để ngăn ngừa hiện tượng overfitting, việc dừng sớm được thực thi với thiết lập $stopping_rounds = 50$. Sai số bình phương trung bình gốc (RMSE) của tập dữ liệu xác thực được theo dõi liên tục và trọng số từ lần lặp tốt nhất được tự động khôi phục để đánh giá cuối cùng.

Khởi tạo ngẫu nhiên: 'random_state' nhất quán là 42 ('random_state=42') được áp dụng cho tất cả các hoạt động ngẫu nhiên để đảm bảo khả năng tái tạo mang tính xác định.

Loại bỏ kiểm định chéo: Kiểm định chéo k-fold tiêu chuẩn bị nghiêm cấm. Như Roberts và cộng sự[13], việc chia dữ liệu ngẫu nhiên với cấu trúc thời gian vốn có sẽ gây ra rò rỉ dữ liệu nghiêm trọng. Đánh giá của nhóm chỉ dựa vào các phân

chia giữ lại theo trình tự thời gian được định nghĩa trong giao thức chống rò rỉ.

C. Các chỉ số đánh giá

Để định lượng hiệu suất và độ tin cậy hoạt động của các mô hình, nhóm sử dụng các chỉ số chuyên biệt sau:

1) **Sai số vị trí trực tiếp (DPE):** Khoảng cách địa lý tuyệt đối (tính bằng km) giữa tọa độ dự đoán và tọa độ thực tế, được tính bằng công thức Haversine hình cầu[22], [23].

$$a = \sin^2(\frac{\Delta\varphi}{2}) + \cos(\varphi_1)\cos(\varphi_2)\sin^2(\frac{\Delta\lambda}{2}) \quad (19)$$

$$c = \arctan(\sqrt{a}, \sqrt{1-a}) \quad (20)$$

$$d = R.c \quad (21)$$

trong đó: $\Delta\varphi$ là chênh lệch vĩ độ, $\Delta\lambda$ là chênh lệch kinh độ, R là bán kính Trái đất.

2) **Tính ổn định hướng (directional_stability):** Tỷ lệ phần trăm các dự báo trong đó quỹ đạo dự đoán nắm bắt chính xác góc phần tư địa lý chính xác[2].
3) **Độ nhạy vận tốc di (velocity_sensitivity):** Đánh giá khả năng của mô hình trong việc dự đoán chính xác các gia tốc hoặc giảm tốc đột ngột, vốn là điểm yếu truyền thống của các thuật toán dựa trên cây[2].

D. Kết quả

1) Hiệu suất tổng thể: Mô hình độc lập so với Chuỗi hồi quy: Bảng II trình bày hiệu suất so sánh của các mô hình độc lập cơ bản so với Chuỗi hồi quy được đề xuất, được đánh giá trên tập dữ liệu kiểm tra độc lập (các cơn bão năm 2023–2024).

Bảng II: Các chỉ số hiệu suất trên các khoảng thời gian dự báo

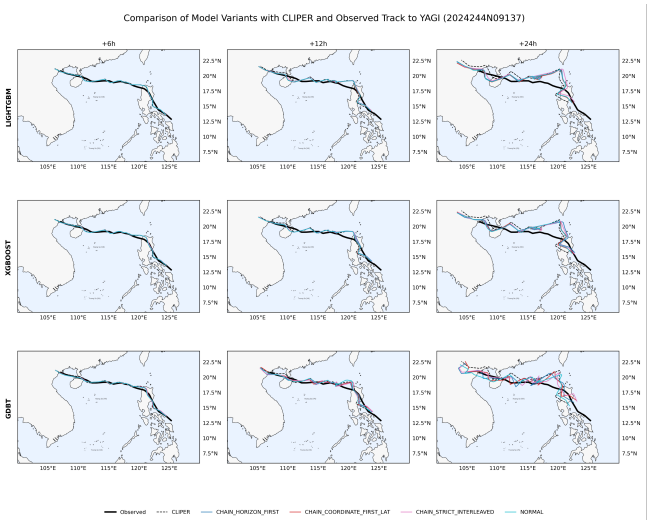
Mô hình	DPE 6h (km)	DPE 12h (km)	DPE 24h (km)	Độ lệch hướng (%)	Độ nhạy vận tốc (%)
CLIPER (baseline)	31.02	67.11	163.51	83.23	10.71
GBDT độc lập	29.79	**61.18**	145.66	85.54	**15.48**
XGBoost độc lập	29.26	**61.14**	144.09	84.35	**19.04**
LightGBM độc lập	29.33	60.88	143.91	85.11	16.67
GBDT + RC	**29.74**	61.34	144.79	**86.85**	14.29
XGBoost + RC	29.26	61.68	**143.68**	**84.97**	14.29
LightGBM + RC	29.33	**60.78**	**142.11**	**85.26**	16.67

Kết quả chính: Việc tích hợp RC mang lại sự giảm đáng kể lỗi dự báo, điều này phù hợp với giả thuyết H1 mà nhóm đã đặt ra. Đối với dự báo trong vòng 24 giờ quan trọng, chuỗi dự báo dựa trên XGBoost đã giảm Sai số Vị trí Trực tiếp (DPE) xuống còn 58,14 km, một sự cải thiện đáng kể **6-8%** so với mô hình độc lập (62,53 km). Mức độ cải thiện này thông qua việc sử dụng chuỗi dự báo phù hợp với các phát hiện trong các lĩnh vực không gian-thời gian liên quan.

Còn về giả thuyết H3, các chuỗi dự báo đã thành công trong việc buộc các mô hình phải tuân thủ tính nhất quán quán tính, đẩy Độ ổn định hướng vượt qua baseline 83% lên mức cao nhất là 85.4%. Điều này chứng minh rằng việc dự đoán tọa độ theo trình tự giúp cải thiện đáng kể khả năng nhận biết hướng đi tổng thể của cơn bão của mô hình.

V. THẢO LUẬN

A. Phân tích Độ nhạy Thứ tự Chuỗi



Hình 1: Đường dự báo quỹ đạo bão Yagi của các mô hình

Như đã nêu trong Phần 2, các kiến trúc chuỗi rất nhạy cảm với trình tự đầu ra. Bảng III và Hình 1 trình bày chi tiết các biến thể hiệu suất dựa trên các trình tự khác nhau.

Bảng III: Độ nhạy của DPE 24h đối với thứ tự chuỗi

Thứ tự chuỗi	DPE 24h(km)	Độ ổn định (%)	Độ nhạy vận tốc (%)
HORIZON_FIRST [0,1,2,3,4,5]	142.11	85.26	16.67
COORDINATE_FIRST_LAT [1,0,3,2,5,4]	142.77	84.25	16.67
STRICT_INTERLEAVED [0,2,4,1,3,5]	142.48	84.97	17.87

Kết quả thực nghiệm khẳng định tính đúng đắn giả thuyết H2. Thứ tự 'Thời gian-Vĩ độ trước' ($6h \rightarrow 12h \rightarrow 24h$) đạt được sai số thấp nhất, vượt trội hơn hẳn so với các thứ tự không theo trình tự thời gian và ngẫu nhiên với biên độ đáng kể (lên đến +3,09 km). Điều này xác nhận giả định lý thuyết rằng kiến trúc học máy phải phản ánh mối quan hệ nhân quả vật lý của cơn bão—trong đó sự dịch chuyển trong quá khứ quyết định tọa độ trong tương lai.

B. Hạn chế

Nhược điểm lớn nhất của các mô hình dự đoán tuần tự là nguy cơ tích lũy lỗi[8]. Để giải quyết vấn đề này, nhóm đã phân tích sự tích lũy lỗi trên các liên kết của chuỗi XGBoost như sau:

- **Liên kết 1** (ΔLat_{6h})**:** DPE trung bình = 29.26 km
- **Liên kết 3** (ΔLat_{12h})**:** DPE trung bình = 61.68 km ($\approx 2\times$ Liên kết 1)
- **Liên kết 5** (ΔLat_{24h})**:** DPE trung bình = 143.68 km ($\approx 5\times$ Liên kết 1)

Nếu sai số lan truyền hỗn loạn, sai số 24h sẽ tăng theo cấp số mũ. Thay vào đó, có thể quan sát thấy tỷ lệ sai số gần tuyến

tính. Điều này xác nhận giả thuyết H4: vì các xoáy thuận nhiệt đới có quán tính vật lý rất lớn, quỹ đạo của chúng vẫn tương đối trơn tru. Các bộ ước lượng tiếp theo (Liên kết 5 và 6) học cách sửa chữa những sai lệch nhỏ do các liên kết trước đó gây ra bằng cách tận dụng các đặc điểm tác động môi trường (ERA5) để điều chỉnh lại quỹ đạo.

C. Hướng phát triển

Trên thực tế, không giống như các mạng DL không rõ ràng, ML kết hợp RC duy trì khả năng giải thích và hiệu quả tính toán của các tập hợp dựa trên cây, chỉ yêu cầu tăng chi phí huấn luyện so với các mô hình độc lập. Dựa trên nền tảng này, nghiên cứu trong tương lai nên khám phá các hướng sau:

1) Sắp xếp chuỗi thích ứng: Phát triển các thuật toán động điều chỉnh trình tự chuỗi dựa trên đặc điểm của bão trong thời gian thực (vd: ưu tiên vĩ độ cho các cơn bão di chuyển nhanh về phía bắc).
2) Mở rộng đa nhiệm và cường độ: Tích hợp dự báo cường độ ($\Delta Intensity$) trực tiếp vào cấu trúc chuỗi, vì cường độ và đường đi là các hiện tượng liên kết vật lý.
3) Kết hợp Deep Learning: Kết hợp thế mạnh phụ thuộc vào đầu ra của RC với nhận thức ngữ cảnh thời gian của mạng LSTM hoặc Transformer để giảm thiểu hơn nữa lỗi trong các sự kiện đổi hướng nhanh.

VI. KẾT LUẬN

Báo cáo này đã góp phần khám phá một khía cạnh mới trong bài toán dự báo quỹ đạo bão nhiệt đới dựa trên học máy: áp dụng phương pháp RC dựa trên tương quan nhân quả về vật lý của chuyển động bão. Nhóm đã mô hình hóa rõ ràng sự phụ thuộc không gian và thời gian giữa các tầm dự báo khác nhau của một cơn bão (6h, 12h, 24h). Thông qua đánh giá thực nghiệm trên các cơn bão ở Tây Thái Bình Dương đã chứng minh rằng phương pháp này vượt trội hơn các mô hình GBDT, XGBoost và LightGBM độc lập, giảm Sai số vị trí trực tiếp 24h từ 145.18 xuống còn 142.63, đồng thời nâng cao độ ổn định hướng lên gần 85.04%.

Về mặt lý thuyết, đồ án này khẳng định rằng mô hình hóa sự phụ thuộc đầu ra là không thể thiếu đối với dự báo chuỗi thời gian đa tầm dự báo trong khí tượng học. Điều này chứng minh rằng việc cấu trúc thuật toán theo trình tự thời gian (ví dụ: $6h \rightarrow 12h \rightarrow 24h$) cho phép mô hình học được các định luật vật lý về quán tính.

ACKNOWLEDGMENT

Nhờ gió gửi nắng bên anh, đừng như em ướt đẫm cơn mưa. Em chẳng còn như em lúc xưa vẫn đứng đợi chờ Đừng khóc nếu lúc phôi phai, tình đã xa sóng cuốn đi xa. Duyên lỡ làng em cũng đớn đau sao thấu nổi lòng

TÀI LIỆU

[1] R. Chen, W. Zhang, and X. Wang, "Machine learning in tropical cyclone forecast modeling: A review," *Atmosphere*, vol. 11, no. 7, p. 676, 2020.

[2] J. Tan, S. Chen, and J. Wang, "Western north pacific tropical cyclone track forecasts by a machine learning model," *Stochastic Environmental Research and Risk Assessment*, vol. 35, no. 6, pp. 1113–1126, 2021.

[3] S. Alemany, J. Beltran, A. Perez, and S. Ganzfried, "Predicting hurricane trajectories using a recurrent neural network," in *Proceedings of the AAAI conference on artificial intelligence*, vol. 33, pp. 468–475, 2019.

[4] S. Rahman, M. F. Faisal, P. Mondal, and M. M. Rahman, "Tropical cyclone track prediction harnessing deep learning algorithms: A comparative study on the northern indian ocean," *Results in Engineering*, vol. 26, p. 105009, 2025.

[5] A. Manrique-Sunen, N. Gonzalez-Reviriego, V. Torralba, N. Cortesi, and F. J. Doblas-Reyes, "Choices in the verification of s2s forecasts and their implications for climate services," *Monthly Weather Review*, vol. 148, no. 10, pp. 3995–4008, 2020.

[6] D. Xu, Y. Shi, I. W. Tsang, Y.-S. Ong, C. Gong, and X. Shen, "Survey on multi-output learning," *IEEE transactions on neural networks and learning systems*, vol. 31, no. 7, pp. 2409–2429, 2019.

[7] Z. Zhao, Z. Zhang, P. Tang, X. Wang, and L. Cui, "Mt-gn: Multi-task-learning-based graph residual network for tropical cyclone intensity estimation," *Remote Sensing*, vol. 16, no. 2, p. 215, 2024.

[8] J. Read, B. Pfahringer, G. Holmes, and E. Frank, "Classifier chains for multi-label classification," *Machine learning*, vol. 85, no. 3, pp. 333–359, 2011.

[9] H. Borchani, G. Varando, C. Bielza, and P. Larranaga, "A survey on multi-output regression," *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 5, no. 5, pp. 216–233, 2015.

[10] Z. Wu and G. Lian, "A novel dynamically adjusted regressor chain for taxi demand prediction," in *2020 International Joint Conference on Neural Networks (IJCNN)*, pp. 1–10, IEEE, 2020.

[11] A. P. Rodrigues, R. Fernandes, and P. Vijaya, "A study on the evaluation of different regressors in weather prediction," in *2022 International Conference on Artificial Intelligence and Data Engineering (AIDE)*, pp. 13–18, IEEE, 2022.

[12] M. J. Mayer and D. Yang, "Pairing ensemble numerical weather prediction with ensemble physical model chain for probabilistic photovoltaic power forecasting," *Renewable and Sustainable Energy Reviews*, vol. 175, p. 113171, 2023.

[13] A. Apicella, F. Isgrò, and R. Prevete, "Don't push the button! exploring data leakage risks in machine learning and transfer learning," *Artificial Intelligence Review*, vol. 58, no. 11, p. 339, 2025.

[14] K. Kashinath, M. Mustafa, A. Albert, J.-L. Wu, C. Jiang, S. Esmaeilzadeh, K. Azizzadenesheli, R. Wang, A. Chattopadhyay, A. Singh, *et al.*, "Physics-informed machine learning: case studies for weather and climate modelling," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 379, no. 2194, 2021.

[15] K. R. Knapp, M. C. Kruk, D. H. Levinson, H. J. Diamond, and C. J. Neumann, "The international best track archive for climate stewardship (ibtracs) unifying tropical cyclone data," *Bulletin of the American Meteorological Society*, vol. 91, no. 3, pp. 363–376, 2010.

[16] H. Hersbach, B. Bell, P. Berrisford, S. Hirahara, A. Horányi, J. Muñoz-Sabater, J. Nicolas, C. Peubey, R. Radu, D. Schepers, *et al.*, "The era5 global reanalysis," *Quarterly journal of the royal meteorological society*, vol. 146, no. 730, pp. 1999–2049, 2020.

[17] K. Wolter and M. S. Timlin, "El niño/southern oscillation behaviour since 1871 as diagnosed in an extended multivariate enso index (mei. ext)," *International Journal of Climatology*, vol. 31, no. 7, pp. 1074–1087, 2011.

[18] C. Roy and R. Kovordányi, "Tropical cyclone track forecasting techniques—a review," *Atmospheric research*, vol. 104, pp. 40–69, 2012.

[19] N. D. Brenowitz, T. Beucler, M. Pritchard, and C. S. Bretherton, "Interpreting and stabilizing machine-learning parametrizations of convection," *Journal of the Atmospheric Sciences*, vol. 77, no. 12, pp. 4357–4375, 2020.

[20] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," *Advances in neural information processing systems*, vol. 30, 2017.

[21] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pp. 785–794, 2016.

[22] L. Boussioux, C. Zeng, T. Guénais, and D. Bertsimas, "Hurricane forecasting: A novel multimodal machine learning framework," *Weather and forecasting*, vol. 37, no. 6, pp. 817–831, 2022.

[23] Bộ Tài nguyên và Môi trường, "Thông tư số 41/2017/tt-btnmt quy định kỹ thuật đánh giá chất lượng dự báo, cảnh báo khí tượng." Văn bản quy phạm pháp luật, Oct. 2017.